

Tema 9-Otros modelos de sistemas conexionistas

Para solucionar los problemas de los mapas de Kohonen se presentaron en los años 90 nuevos modelos de mapas autoorganizativos. Para ello apareció una nueva filosofía: el crecimiento de redes.

Consiste en inicializar el aprendizaje con un conjunto pequeño de elementos de proceso y que sea la red quien determina su estructura. Se generan a partir del entrenamiento de la red. De esta manera se mejora la preservación de la topología de las redes de Kohonen.

Para insertar neuronas se incluye un nuevo concepto, el valor resource o error de cuantización. Es un valor que indica lo lejos que está una neurona del valor que se espera obtener. Se obtiene del error con respecto a los patrones de entrada. Tras cierto número de modificaciones de pesos se mira la necesidad de añadir nuevas neuronas. En las neuronas nuevas su vector de pesos y el valor resource se calculan a partir de las vecinas.

El borrado de neuronas se da cuando el conjunto de patrones de entrada tiene una probabilidad muy baja de que sirvan para activar alguna neurona en concreto.

Growing Cell Structures (GCS)

Su principal ventaja es la dinamicidad de la capa de salida durante el entrenamiento. Es orientada a cuantificación vectorial. La adición de neuronas se hace donde haya más patrones de entrenamiento. La salida son estructuras básicas. El problema que presentan es que tiene pocos parámetros de entrenamiento que son difíciles de interpretar.

El objetivo es construir una estructura cuyos vectores de entrenamiento se distribuyan de acuerdo a la entrada. Los patrones de entrada similares se agrupan en neuronas próximas, las vecinas agrupan patrones similares y las regiones del espacio de entrada con una densidad alta se representan con un número elevado de neuronas.

Se diferencian de Kohonen en la topología de la capa de salida. En cuanto a la dinámica de procesamiento de vectores, el entrenamiento en GCS sigue siendo competitivo, lo que significa que las neuronas compiten entre sí para convertirse en la Mejor Unidad de Coincidencia (Best Matching Unit, BMU) para un patrón de entrada dado. Cada neurona en GCS tiene un vector de pesos que representa su posición en el espacio de entrada y un contador que almacena el error de cuantización, que es el cuadrado de la distancia euclidiana entre el patrón de entrada y la neurona ganadora (BMU).

En el entrenamiento de GCS, se utilizan dos tasas de aprendizaje diferentes. Una tasa de aprendizaje, denotada por α_1 , se utiliza para modificar los pesos de la BMU, es decir, la

neurona ganadora. La otra tasa de aprendizaje, denotada por α_2 , se utiliza para modificar los pesos de las vecinas inmediatas de la BMU. Esto implica que las vecinas inmediatas también se actualizan durante el entrenamiento, lo que permite que las neuronas se adapten y se ajusten a los patrones de entrada.

A diferencia de otros enfoques de SOM donde se utiliza una función de vecindad que varía durante el entrenamiento, en GCS solo se modifican los pesos de las vecinas inmediatas. Esto significa que no hay una propagación gradual del ajuste de pesos a través de un área vecina amplia, sino que se limita a las neuronas más cercanas a la BMU.

Sirven, por ejemplo, para el diagnóstico de tumores en cadenas de ADN.

Growing Neutral Gas (GNG)

A diferencia del modelo "Growing Cell Structures" (GCS), el GNG no mantiene una estructura k-dimensional estricta o fija en la capa de salida de la red durante el proceso de inserción y eliminación de neuronas.

El GNG se adapta a diferentes dimensiones y puede ajustar la dimensión de la estructura que utiliza en función de los datos de entrada. Esto significa que puede variar y adaptarse a la complejidad de los datos, lo que lo hace más flexible en términos de la dimensionalidad de la estructura.

A diferencia del GCS, el GNG trabaja más con aristas que con triángulos. En lugar de enfocarse en estructuras tridimensionales, la red GNG se basa en la inserción y eliminación de aristas para adaptarse a los vectores de entrada. Las aristas representan las conexiones entre las neuronas en la red.

Los parámetros en el GNG se mantienen constantes durante el proceso de aprendizaje. A diferencia de otros modelos donde los parámetros pueden cambiar durante el entrenamiento, en el GNG se mantienen fijos, lo que proporciona una mayor estabilidad en el proceso de aprendizaje.

En cuanto a las conexiones de vecindad, en los mapas de Kohonen las conexiones vecinas son laterales y forman una cruz en cada unidad. En cambio, en el GNG, una unidad puede tener más de cuatro vecinos y generar diversas figuras geométricas. Esto amplía la capacidad de aprendizaje y adaptabilidad de la red, ya que puede establecer conexiones más flexibles entre las neuronas.

Se adapta a diferentes dimensiones y puede ir variando la dimensión de la estructura dimensional que emplea en función de los datos de entrada.

Una aplicación es, por ejemplo, la lectura óptica de caracteres.

