

Tema 9-Otros modelos de sistemas conexionistas

La autoorganización en biología es el proceso a través del cual el comportamiento global de un sistema se obtiene como resultado de la interacción local entre sus componentes. En sistemas conexionistas consiste en la modificación repetidas veces de los pesos de las conexiones en respuesta a modos de activación según unas reglas preestablecidas hasta el desarrollo final del sistema. Las características de la autoorganización son:

- No existen observadores globales, no se determina el comportamiento y no tiene por que terminar en la salida deseada.
- Tienen un comportamiento emergente, es decir, hay características que aparecen de forma inesperada.
- Los datos deben ser lo suficientemente redundantes para sacar de ellos características.

Sirven, por ejemplo, para agrupar páginas web según su temática, fotos de personas según sus rasgos... Para estos casos algo muy necesario es el reconocimiento de patrones. Un patrón es una entidad representada por un conjunto de propiedades y las relaciones que existen entre ellas.

Mapas autoorganizativos (SOM)

La ubicación espacial de las células nerviosas es muy importante. Por ejemplo, en la corteza auditiva se distribuyen en función según frecuencia y tonalidad y las de la corteza visual en columnas según las características que comparten. El orden de las unidades de proceso del cerebro también es importante. El orden sirve para que células idénticas tengan una diferente funcionalidad.


Que la representación del conocimiento pueda asumir la forma de un mapa de características ha dado lugar a nuevos modelos de redes neuronales artificiales. La localización de la neurona en la red, especifica un orden topológico que describe la relación de similitud entre los patrones de entrada.

Mapas autoorganizativos de Kohonen

En 1982 el científico Kohonen diseñó un modelo llamado mapa autoorganizativo de características, una red neuronal de 2 capas (entrada y competición o salida). Es un modelo de red neuronal que tiene capacidad para formar mapas de características, simulando los mapas topológicos de los fenómenos sensoriales existentes en el cerebro a través de una matriz de neuronas artificiales.

Son útiles para mostrar de forma simplificada los datos de entrada y las relaciones entre ellos. Su principal función es proyectar datos altamente dimensionales en un esquema de bajas dimensiones. Además permiten encontrar visualmente similitudes entre los datos.

Son redes no supervisadas, es decir, procesan datos sin la necesidad de etiquetas o respuestas predefinidas. Se basan en el aprendizaje competitivo: las células compiten por aprender modificando sus pesos, pero solo se consigue una célula ganadora. Se hace actualizando los pesos de las neuronas para que se asemeje al patrón de entrada. A medida que se presenta un conjunto de patrones de entrada al SOM y se actualizan los pesos de las neuronas ganadoras y sus vecinas, las neuronas de la capa competitiva comienzan a agruparse en clústeres o grupos. Cada neurona representa un prototipo o centroide del grupo de patrones de entrada similares asociados a ella. Los clústeres generados por el SOM permiten visualizar la estructura subyacente de los datos y facilitan la identificación de similitudes y diferencias entre ellos.



Las principales características de los mapas autoorganizativos de Kohonen son:

- Topología predefinida de neuronas en el mapa, el aprendizaje conserva la relación topológica (orden topográfico).
- La vecindad entre neuronas preserva las relaciones topológicas, es decir, las neuronas cercanas presentan patrones similares.
- Buscan agrupar datos similares. Cada grupo de patrones está representado por unos pesos (prototipo de la neurona). Los prototipos se usan para categorizar patrones nuevos desconocidos.

- Si un patrón pertenece a una categoría refuerza la representación de esta. En caso de que no pertenezca a ninguna los pesos de la red se ajustarán para reconocer a la nueva categoría.

La capa de entrada es la que recibe la señal de entrada a la red. La dimensión de esta depende del número de atributos de los patrones de entrada. Cada neurona de entrada conecta con todas las de la capa de competición (no hay conexiones entre las de competición). Se puede calcular la distancia euclídea entre los pesos de las neuronas de entrada y los de las capas de competición.

El funcionamiento de estos se divide en dos partes: aprendizaje y operación.

El objetivo de la fase de aprendizaje es acercar los pesos a los patrones de entrada. Los pesos de las conexiones se inicializan de forma aleatoria, se introducen los patrones un número suficiente de veces, se realiza el cálculo de distancias y gana la neurona de menor distancia. Luego, se modifican los pesos de la neurona ganadora.

La vecindad indica que células aprenden cuando se activa una neurona. Se va reduciendo poco a poco. Está regulada por:


- **Radio de vecindad:** alcance de las neuronas afectadas por la vecindad
- **Topología de vecindad:** neuronas que son vecinas inmediatas
- **Función de vecindad:** grado de vecindad con respecto al centro (distancia ganadora)

Las neuronas pertenecientes a la región de vecindad también se modifican.

El algoritmo de aprendizaje es el siguiente:

Tendencia del proceso de aprendizaje: cada neurona tiende a colocarse en el centroide de aquellos grupos de ejemplos de entrada para los cuales es la neurona ganadora

1. Inicializar pesos
 - Asignar a los pesos valores pequeños aleatorios
2. Presentar una entrada
 - El conjunto de aprendizaje (ξ) se presenta repetidas veces hasta llegar a la convergencia de la red
 - Actualizar α (ir reduciendo su valor)
3. Propagar el patrón de entrada hasta la capa de competición
 - Obtener los valores de salida (distancias) de las neuronas de dicha capa
4. Seleccionar la neurona ganadora (BMU – *best-matching unit*)
 - La de menor distancia al patrón
5. Actualizar conexiones entre capa de entrada y la BMU
 - Actualizar también los pesos de sus vecinas según el grado de vecindad
 - 1. Fase Ordenación: valores altos de α y radio vecindario. 2. Fase Convergencia: valores bajos
6. Si α se mantiene por encima del umbral de parada (o no se ha llegado a T iteraciones), volver a 2, en caso contrario FIN




Se repite el entrenamiento N veces con una configuración inicial diferente. Para determinar la calidad del SOM se emplean el error de cuantización medio (se elige el menor error entre las conexiones de las BMU y los patrones de entrada) y las medidas de preservación de la topología (técnicas o métricas utilizadas para evaluar en qué medida un modelo o algoritmo de aprendizaje preserva la estructura topológica de los datos durante el procesamiento).


En el modo operación se introduce un patrón de entrada para conocer su prototipo. Cada neurona de salida calcula la similitud entre el vector de entrada y los pesos y gana la neurona con más similitud.

Representación geométrica:

Los ejemplos y los prototipos (pesos de las neuronas de la capa competitiva) se pueden representar como puntos en un espacio n-dimensional.



Las coordenadas de los prototipos son los pesos de las células de la capa competitiva.



Un mapa de Kohonen representa una red correcta si no se cruzan las líneas.

Sirven para:

- Agrupamiento de patrones o clustering: separar en grupos
- Prototipado: obtener prototipo del grupo al que pertenece cada patrón
- Análisis de componentes principales
- Extracción de características
- Problema del viajante
- Delimitar un vaso sanguíneo
- Hacer un mapa de la pobreza mundial

Las ventajas de los SOM son:

- Son transparentes a los datos de entrada
- Permiten integrar otras técnicas
- Permiten visualizar fácil el resultado

Los inconvenientes son:

- La dimensión de la red se fija a priori
- Pueden quedar neuronas sin entrenar
- No se puede confirmar si la neurona vencedora es lo suficientemente buena
- Son costosos computacionalmente